

Raport Techniczny: Budowa Modelu Scoringowego Oceny Ryzyka Kredytowego

Cezary Polkowski, Mateusz Stasiak

1 grudnia 2025

Streszczenie

Niniejszy dokument stanowi techniczne podsumowanie procesu budowy, walidacji i kalibracji modeli predykcyjnych służących do oceny ryzyka niewypłacalności (default). Celem projektu było opracowanie dwóch niezależnych silników scoringowych (modelu interpretowalnego oraz modelu typu „black-box”) oraz ich kalibracja do zadanego poziomu tendencji centralnej PD (Probability of Default) wynoszącego 4%.

1 Streszczenie Menedżerskie (Executive Summary)

W ramach prac projektowych przetestowano i zweryfikowano szereg algorytmów uczenia maszynowego. Na podstawie wielokryterialnej analizy, uwzględniającej skuteczność (AUC), stabilność oraz — kluczową w sektorze bankowym — wyjaśnialność decyzji, dokonano następującego wyboru:

- **Model Champion (Wdrożeniowy):** Oparty o **Regresję Logistyczną** z transformacją Weight of Evidence (WoE). Wybór podyktowany jest pełną transparentnością modelu, brakiem tendencji do przeuczenia oraz wysoką zgodnością z wymogami regulacyjnymi (prawo do wyjaśnienia).
- **Model Challenger (Referencyjny):** Oparty o algorytm **XGBoost**. Model ten posłużył jako punkt odniesienia (benchmark) do oceny potencjału nieliniowych zależności w danych.

Kluczowe Wyniki i Uzasadnienie Decyzji

1. Skuteczność vs Wyjaśnialność

Model XGBoost osiągnął nieznacznie wyższą skuteczność na zbiorze testowym (AUC 76.5%) w porównaniu do Regresji Logistycznej (AUC 74.3%). Jednakże analiza stabilności wykazała, że XGBoost ma tendencję do overfittingu (duży spadek jakości między zbiorem treningowym a testowym), podczas gdy Regresja Logistyczna zachowuje się niezwykle stabilnie. Uznano, że przyrost AUC o 2.2 p.p. nie uzasadnia ryzyka wdrożenia modelu "black-box", który jest trudny w interpretacji i monitoringu.

Tabela 1. Porównanie skuteczności modeli na zbiorze testowym

Model	Dataset	ROC AUC	Gini	PR AUC	KS	Brier Score
XGBoost (Challenger)	Test	0.7652	0.5304	0.2928	0.4267	0.0778
Logit_WoE (Champion)	Test	0.7430	0.4861	0.2385	0.3917	0.0799

2. Kalibracja do Celu Biznesowego (PD \approx 4%)

Wyjściowe modele charakteryzowały się średnim poziomem predykcji ryzyka w granicach 9-10%. Zgodnie z wymaganiami, przeprowadzono rekalkibrację metodą *Isotonic Regression + Calibration-in-the-large*. Dla wybranego modelu Logit_WoE uzyskano średnie PD na poziomie **4.44%**, co jest wynikiem satysfakcjonującym biznesowo, mimo technicznego wzrostu błędu kalibracji (ECE wzrosło do 0.0598).

Rekomendacja

Rekomenduje się wdrożenie modelu **Regresji Logistycznej (WoE)** w wariacie skalibrowanym *Iso+Large* 4%. Model ten zapewnia optymalny kompromis między precyzją predykcji a bezpieczeństwem operacyjnym i prawnym instytucji.

2 Definicja Problemu i Podejście Metodyczne

Celem projektu jest budowa systemu scoringowego, który pozwoli na efektywną ocenę wiarygodności kredytowej podmiotów gospodarczych na podstawie danych finansowych. Klucowym wymogiem biznesowym jest zachowanie ścisłej interpretowalności wyników (White-box model) oraz precyzyjna kalibracja prawdopodobieństwa niewypłacalności (PD) do zadanego poziomu 4%.

2.1 Definicja Zmiennej Celu (Target)

Zmienną objaśnianą w modelach jest binarna flaga **default**, przyjmująca wartość 1 w przypadku wystąpienia zdarzenia niewypłacalności w zdefiniowanym horyzoncie czasowym, oraz 0 dla podmiotów terminowo regulujących zobowiązania ("dobrzy klienci").

2.2 Strategia Walidacji i Podział Danych

Aby zapewnić rzetelną ocenę zdolności uogólniania modeli, zastosowano podział zbioru danych w proporcjach **60/20/20**:

- **Zbiór Treningowy (Train - 60%)**: Estymacja wag modelu logistycznego i budowa drzew.
- **Zbiór Testowy (Test - 20%)**: Optymalizacja hiperparametrów i wczesna detekcja overfittingu.
- **Zbiór Walidacyjny (Validation - 20%)**: Ostateczny zbiór "Hold-out", na którym podjęto decyzję o wyborze modelu interpretowalnego jako championa.



Rysunek 1. Schemat podziału danych zastosowany w procesie modelowania.

3 Charakterystyka Danych i Inżynieria Cech (EDA)

3.1 Jakość Danych i Braki (Data Quality)

Analiza kompletności danych ujawniła krytyczne braki w zmiennych przepływowych. Tabela 2 prezentuje zmienne wykluczone z analizy ze względu na braki przekraczające 95%.

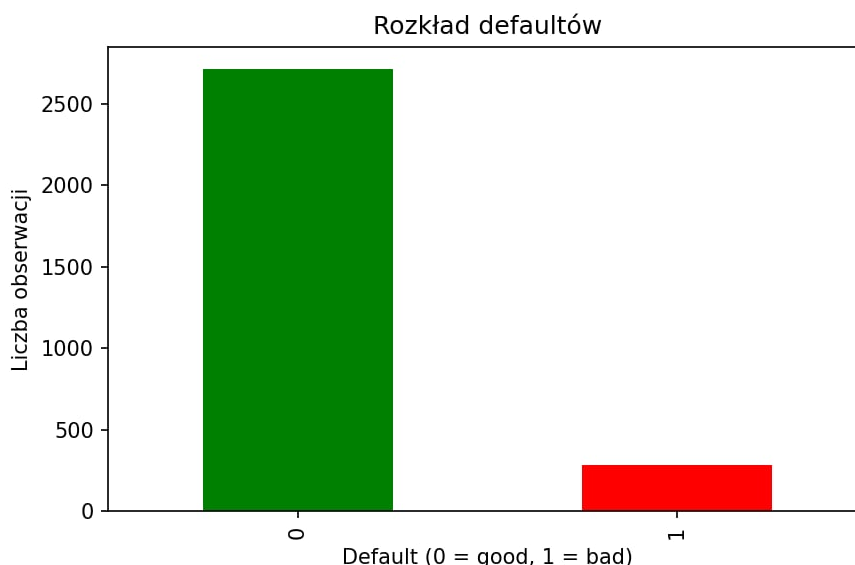
Tabela 2. Zmienne o krytycznym poziomie braków danych (powyżej 95%)

Zmienna	Liczba braków
wsk_akt_generowania_got_2	2966
wsk_pokrycie_wyd_fin_gotowkowe_2	2966
RP_przepływy_operacyjne	2966
RP_amortyzacja	2838
wsk_kapital_do_aktywa	44

Zastosowano transformator `HighMissingDropper`, eliminując zmienne o niskiej jakości. Pozostałe braki uzupełniono medianą (imputacja).

3.2 Rozkład Zmiennej Celu (Target Distribution)

Zbiór danych charakteryzuje się niezbilansowaniem klas.




Rysunek 2. Rozkład licznosci klas w zbiorze danych (0 = Good, 1 = Bad).

Rzeczywisty odsetek defaultów (Target Rate) w próbie wynosi ok. **10%** (Rysunek 2). Jest to istotna informacja w kontekście późniejszej konieczności silnej kalibracji w dół (do 4%).

3.3 Korelacje i Pipeline

Zidentyfikowano silną współliniowość między miarami zysku (`zysk_netto` vs `zysk_brutto`). W modelu logistycznym zastosowano selekcję cech (VIF/Korelacja < 0.9), aby uniknąć niestabilności estymatorów. Rysunek 3 prezentuje macierz korelacji dla kluczowych zmiennych.



Rysunek 3. Macierz korelacji Spearmana dla top 10 zmiennych vs default.

Zastosowano dedykowany pipeline dla modelu docelowego: dyskretyzację zmiennych (Binning) oraz transformację WoE (Weight of Evidence), która linearyzuje zależności i obsługuje wartości skrajne.

4 Budowa i Wyniki Modeli Predykcyjnych

W tej sekcji przedstawiono wyniki budowy dwóch modeli, ze szczególnym naciskiem na model Regresji Logistycznej, który został wybrany do wdrożenia.

4.1 Model Champion: Regresja Logistyczna (WoE)

Model oparto o transformację WoE, co pozwala na budowę klasycznej karty punktowej (Scorecard).

4.1.1 Parametry Modelu

Tabela 3 prezentuje zmienne, które weszły do ostatecznego modelu. Wszystkie cechy posiadają interpretację ekonomiczną zgodną z intuicją (ujemne bety oznaczają, że wzrost cechy obniża ryzyko).

Tabela 3. Oszacowania współczynników modelu regresji logistycznej

Zmienna	Współczynnik (Beta)
Intercept	-2.2145
formaWlasnosci_Symbol	-0.2301
Zobowiazania_dlugoterminowe	-0.4732
wsk_ROA	-0.4608
wsk_mnoznik_kap_wl	-0.3347
wsk_koszty_przychody	-0.3587
wsk_zadluzenia_pozyczki_dlugie	-0.1896
wsk_rotacja_zobowiazan_dostaw_uslug	-0.3229
wsk_poziom_kapitalu_obrotowego_netto	-0.6661
wsk_zob_s_aktywa_rzeczowe	-0.4982

Kluczowym sterownikiem modelu jest **płynność** (`wsk_poziom_kapitalu_obrotowego_netto`), co jest typowe dla modeli upadłościowych MŚP.

Interpretacja ekonomiczna zmiennych w modelu

Wszystkie współczynniki w modelu przyjmują wartości ujemne, co oznacza, że wzrost danej zmiennej (przy pozostałych na stałym poziomie) obniża log-iloraz szans wystąpienia zdarzenia niekorzystnego (defaultu). Poniżej przedstawiono ekonomiczną interpretację poszczególnych zmiennych.

formaWlasnosci_Symbol Zmienna odzwierciedla formę własności lub strukturę organizacyjno-prawną przedsiębiorstwa. Określone formy własności (np. własność prywatna, spółki kapitałowe) wiążą się często z lepszym nadzorem właścicielskim, większą przejrzystością finansową oraz większą dbałością o efektywność. Ujemny współczynnik sugeruje, że firmy o bardziej sprzyjającej strukturze własności charakteryzują się niższym ryzykiem niewypłacalności.

Zobowiazania_dlugoterminowe Zmienna opisuje poziom zobowiązań długoterminowych w strukturze finansowania. Umiarkowany poziom długu długoterminowego może świadczyć o bardziej stabilnym finansowaniu inwestycji, podczas gdy nadmierne zadłużenie zwiększa ryzyko problemów z obsługą odsetek. Ujemny współczynnik wskazuje, że wyższe (ale kontrolowane) wykorzystanie finansowania długoterminowego wiąże się z niższym prawdopodobieństwem defaultu, co może odzwierciedlać selekcję przedsiębiorstw zdolnych do pozyskania długoterminowego kapitału na relatywnie dobrych warunkach.

wsk_ROA (Rentowność aktywów) Rentowność aktywów informuje, jak efektywnie przedsiębiorstwo wykorzystuje posiadane aktywa do generowania zysku. Wyższy ROA oznacza lepszą kondycję ekonomiczną i większą zdolność do generowania nadwyżek finansowych, które mogą zostać przeznaczone na obsługę zobowiązań. Ujemny współczynnik przy ROA jest zatem zgodny z intuicją – firmy bardziej rentowne są mniej zagrożone niewypłacalnością.

wsk_mnoznik_kap_wl (Mnożnik kapitału własnego) Mnożnik kapitału własnego odzwierciedla poziom dźwigni finansowej, czyli relację między aktywami a kapitałem własnym. Wyższy mnożnik oznacza większy udział finansowania obcego w stosunku do własnego, a więc większe obciążenie ryzykiem dźwigni. Ujemny współczynnik wskazuje, że niższy poziom dźwigni (czyli ostrożniejsza struktura finansowania) zmniejsza ryzyko defaultu, co jest spójne z klasyczną teorią finansów przedsiębiorstw.

wsk_koszty_przychody Wskaźnik relacji kosztów do przychodów mierzy efektywność operacyjną. Im niższa wartość wskaźnika, tym większa jest marża operacyjna i potencjał generowania zysków. Przedsiębiorstwa, które utrzymują koszty na rozsądnym poziomie względem przychodów, są bardziej odporne na spadki sprzedaży i zaburzenia rynkowe. Ujemny współczynnik oznacza więc, że lepsza kontrola kosztów obniża prawdopodobieństwo niewypłacalności.

wsk_zadluzenia_pożyczki_długie Wskaźnik ten opisuje stopień zadłużenia z tytułu długoterminowych pożyczek. Nadmierne zadłużenie zwiększa ryzyko niewypłacalności przez rosnące obciążenia odsetkowe, jednak pewien poziom długu jest naturalny i może wspierać rozwój. Ujemny współczynnik sugeruje, że w analizowanej próbie przedsiębiorstwa o niższym udziale długoterminowych pożyczek charakteryzują się lepszym profilem ryzyka kredytowego.


wsk_rotacja_zobowiazan_dostaw_uslug Rotacja zobowiązań wobec dostawców i usługodawców jest miarą sprawności regulowania zobowiązań krótkoterminowych. Wyższa rotacja świadczy o szybszym spłacaniu zobowiązań i lepszej płynności operacyjnej. Ujemny współczynnik wskazuje, że przedsiębiorstwa sprawniej zarządzające zobowiązaniami bieżącymi rzadziej doświadczają problemów z wypłacalnością.

wsk_poziom_kapitalu_obrotowego_netto Kapitał obrotowy netto odzwierciedla zdolność przedsiębiorstwa do pokrycia zobowiązań krótkoterminowych za pomocą aktywów obrotowych. Wyższy poziom kapitału obrotowego oznacza większą poduszkę płynnościową i większą elastyczność finansową w krótkim okresie. Silnie ujemny współczynnik jest zgodny z intuicją: firmy z lepszą płynnością bieżącą wykazują istotnie niższe ryzyko defaultu.

wsk_zob_s_aktywa_rzeczowe Wskaźnik ten opisuje relację zobowiązań do aktywów rzeczowych (majątku trwałego). Niższy udział zobowiązań w finansowaniu majątku trwałego oznacza bardziej konserwatywną strukturę finansowania i mniejsze obciążenie długiem zabezpieczonym na aktywach. Ujemny współczynnik sugeruje, że firmy, które w mniejszym stopniu finansują aktywa rzeczowe długiem, są mniej narażone na problemy z wypłacalnością.

4.1.2 Ocena Jakości: Krzywe ROC i PR


Model charakteryzuje się solidną zdolnością separacyjną ($AUC = 0.743$).



Rysunek 4. Krzywa ROC oraz Precision-Recall dla modelu Regresji Logistycznej.

4.2 Model Challenger: XGBoost i Analiza Overfittingu

Model XGBoost, mimo teoretycznie wyższej skuteczności, wykazał niepokojące objawy przeuczenia.



Rysunek 5. Krzywe uczenia modelu XGBoost (Log-loss na zbiorze Train vs Test).

Analiza krzywych uczenia (Rysunek 5) pokazuje, że strata na zbiorze testowym (linia pomarańczowa) przestaje maleć po ok. 40 iteracjach, podczas gdy na zbiorze treningowym (linia niebieska) wciąż spada. Sugeruje to, że model zaczyna dopasowywać się do szumu.

4.3 Decyzja o Wyborze Modelu

Tabela 4. Porównanie stabilności modeli (Train vs Test)

Model	Zbiór	AUC	Gini	KS	Log-loss
Regresja Logistyczna	Train	0.7416	0.4831	0.3559	0.2820
Regresja Logistyczna	Test	0.7430	0.4861	0.3917	0.2817
XGBoost	Train	0.9432	0.8865	0.7548	0.1985
XGBoost	Test	0.7652	0.5303	0.4267	0.2731

Z tabeli 4 wynika, że Regresja Logistyczna jest modelem ****niezwykle stabilnym**** (brak różnic Train vs Test), podczas gdy XGBoost traci blisko 18 p.p. AUC na zbiorze testowym. Biorąc pod uwagę wymogi bankowe, wybrano model stabilniejszy.

5 Kalibracja Probabilistyczna

Zadaniem kalibracji było sprowadzenie predykcji modelu Championa (Logit) do średniego poziomu $PD = 4\%$.

5.1 Metodyka i Wyniki

Zastosowano metodę hybrydową *Isotonic Regression + Calibration-in-the-large*.

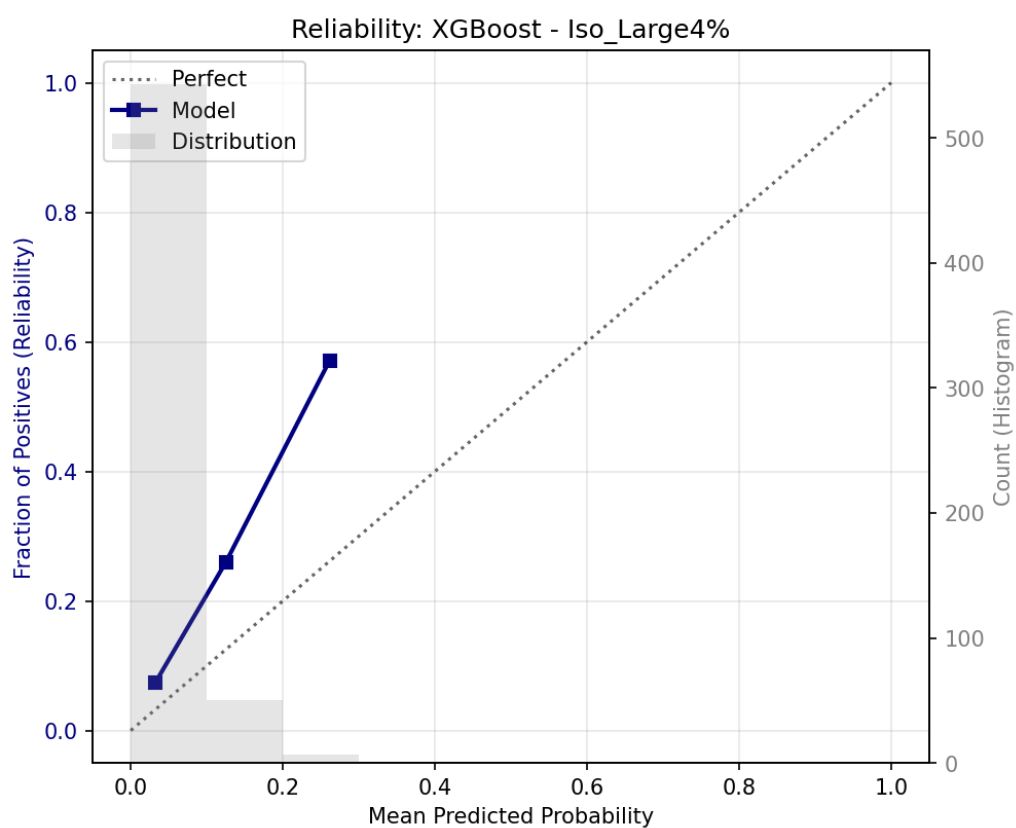
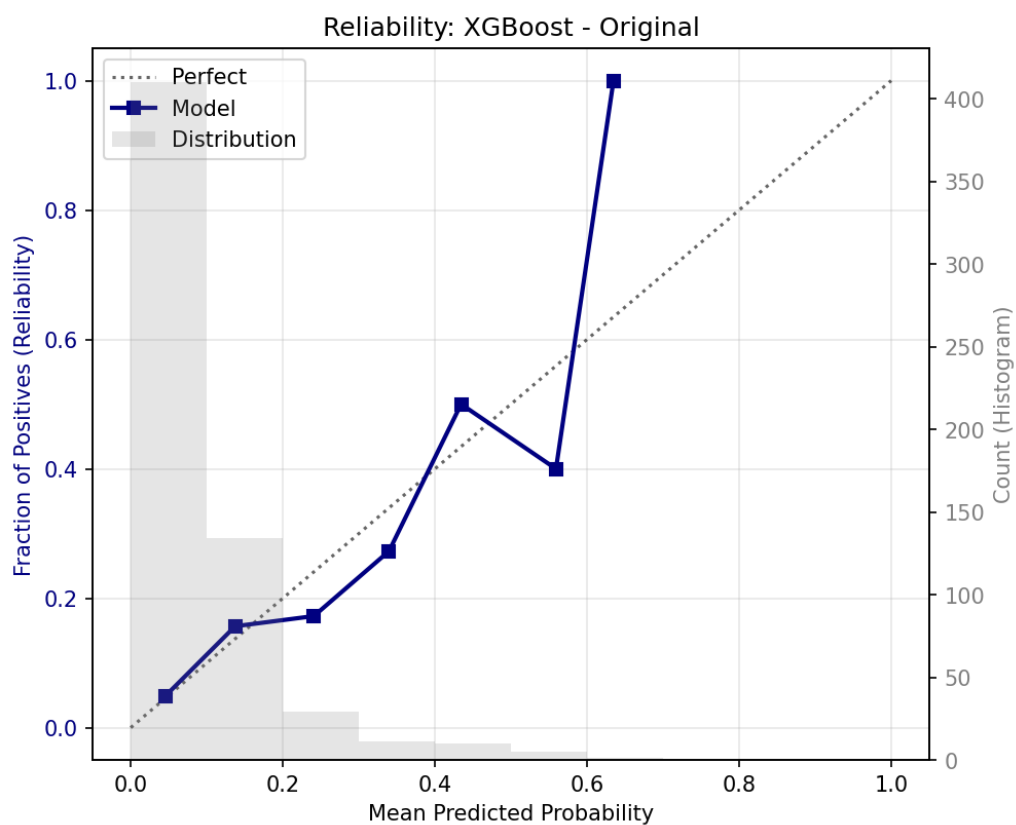
Tabela 5. Wyniki kalibracji (zestawienie metryk)

Metoda	Avg PD	ECE	Brier Score	Reliability (REL)
<i>Model Logit (Champion)</i>				
Logit Original	9.80%	0.0115	0.0799	0.0004
Logit Iso+Large4%	4.44%	0.0598	0.0884	0.0073
<i>Model XGBoost (Challenger)</i>				
XGBoost Original	9.25%	0.0142	0.0778	0.0009
XGBoost Iso+Large4%	4.27%	0.0523	0.0833	0.0042

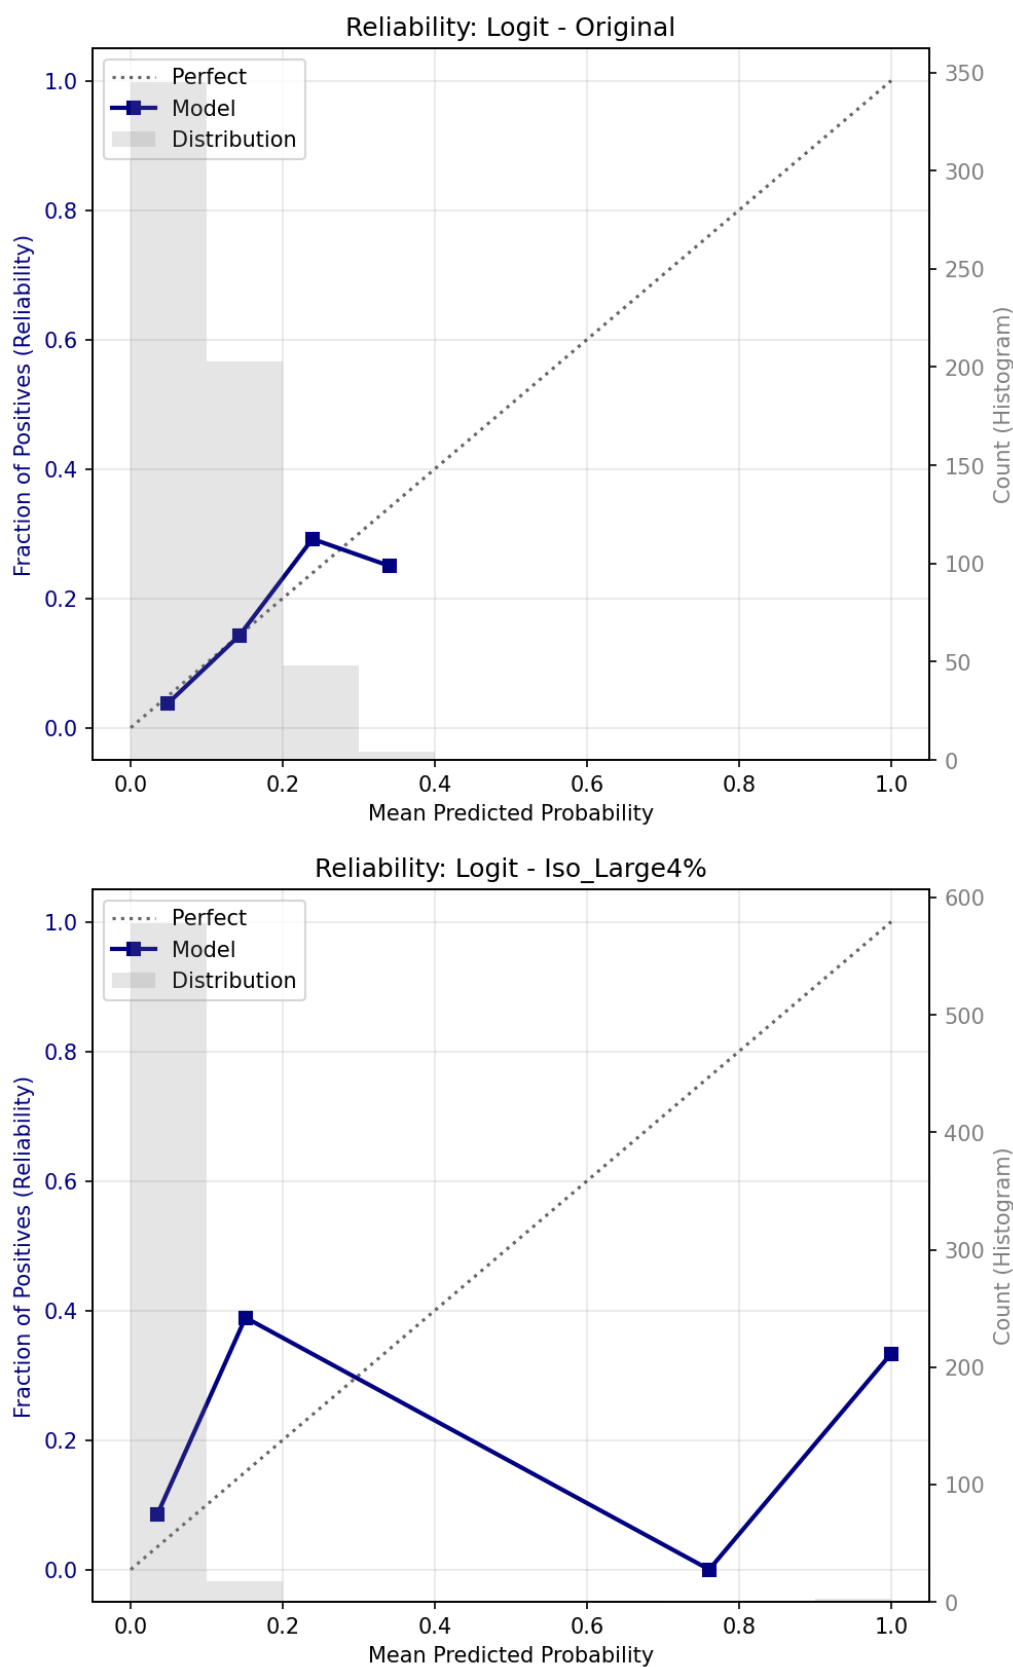
Dla modelu Logit udało się zredukować średnie PD z 9.80% do ****4.44%****. Wzrost błędu ECE (z 0.01 na 0.05) jest kosztem poniesionym za realizację celu biznesowego.

5.1.1 Analiza Graficzna Kalibracji

Na Rysunku 6 (przedstawiającym analogiczny proces dla modelu XGBoost) widać, jak metoda *Iso+Large4%* przesuwa rozkład w stronę niższych wartości (fioletowa linia). Podobny efekt uzyskano dla Logita.



Rysunek 6. Krzywa niezawodności (Reliability Curve) oraz histogram dla modelu XGBoost.



Rysunek 7. Krzywa niezawodności (Reliability Curve) dla modelu Logit.

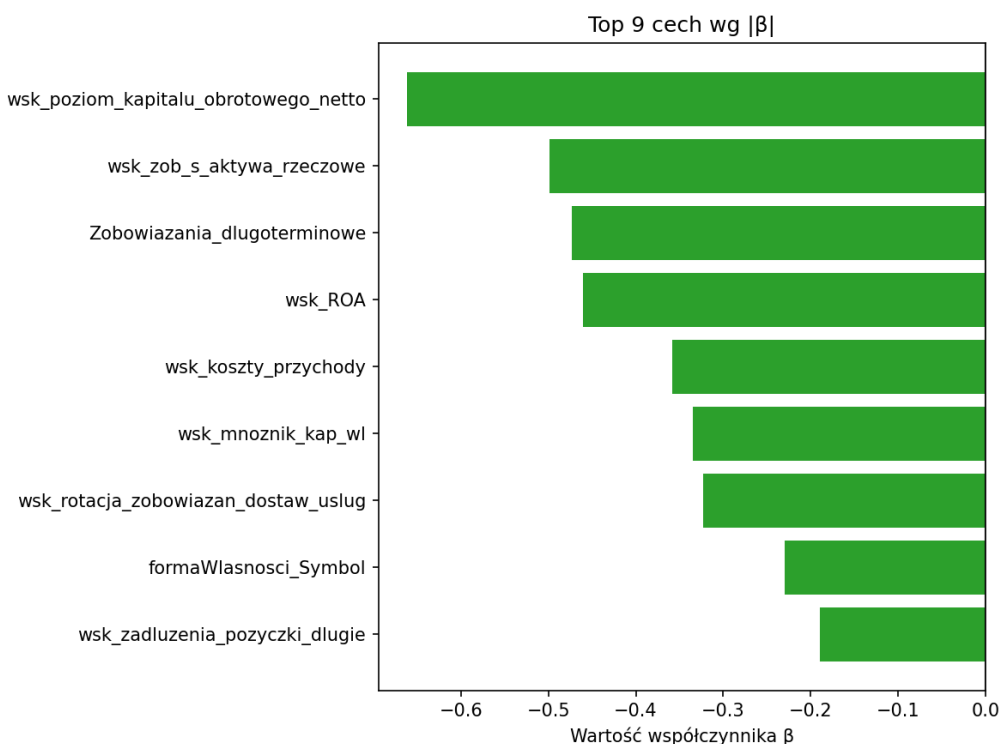
Wykres niezawodności dla Logita (Rysunek 7) potwierdza, że po kalibracji (fioletowa linia) model systematycznie zaniża predykcje (leży powyżej przekątnej), co jest wymuszone celem 4%, ale zachowuje monotoniczność.

6 Analiza Złożoności i Walidacja Hipotez (XAI na przykładzie Challenge'a)


Chociaż do wdrożenia wybrano model liniowy, przeprowadzono zaawansowaną analizę wyjaśnialności (SHAP) dla modelu XGBoost (Challenger). Celem tej analizy było potwierdzenie, czy model liniowy nie pomija kluczowych nieliniowych zależności oraz czy "intuicja" modelu black-box pokrywa się z logiką modelu scorecardowego.

6.1 Interpretacja Globalna: Potwierdzenie Kluczowych Cech

Ranking ważności cech w modelu XGBoost (Rysunek 9) potwierdza słuszność doboru zmiennych w Regresji Logistycznej (Rysunek 8).



Rysunek 8. Ranking ważności cech (SHAP) dla modelu Regresji Liniowej.




Rysunek 9. Ranking ważności cech (SHAP) dla modelu Challenger (XGBoost).

Najważniejsze zmienne w XGBoost to **Kapitał Własny** oraz **Kapitał Obrotowy Netto**. Są to te same obszary (struktura kapitału i płynność), które okazały się istotne statystycznie w modelu Logit (gdzie `wsk_poziom_kapitalu_obrotowego_netto` miał najwyższą statystykę Walda). Waliduje to ekonomiczną poprawność modelu liniowego.

6.1.1 Charakter Wpływu (Beeswarm Plot)

Wykres Beeswarm (Rysunek 10) pokazuje, że nawet w modelu nieliniowym, kierunki wpływu są zazwyczaj monotoniczne.

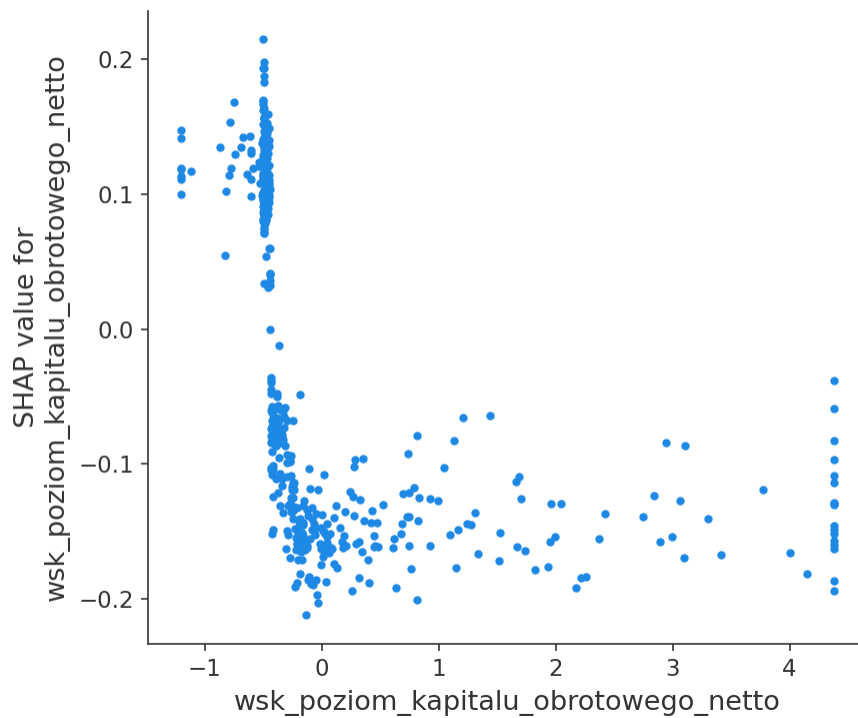


Rysunek 10. Wykres SHAP Beeswarm: Kierunki wpływu cech na ryzyko.

Wysoki kapitał własny (czerwone punkty) obniża ryzyko (wartości SHAP ujemne), co jest zgodne z ujemnym znakiem parametru w regresji logistycznej.

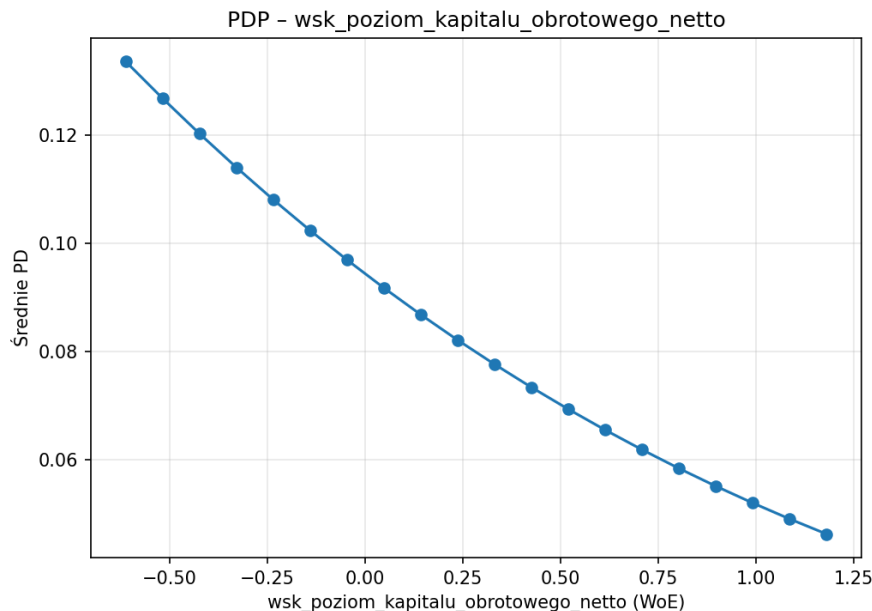
6.1.2 Analiza Punktów Przegięcia (Dependence Plots)

Analiza wykresów zależności (Dependence Plots) pozwala zrozumieć, gdzie leżą "progi bólu" dla firm.



Rysunek 11. Analiza zależności dla Kapitału Obrotowego Netto (Model Challenger).

Na Rysunku 11 widać, że ryzyko gwałtownie rośnie, gdy kapitał obrotowy spada poniżej zera. Model liniowy aproksymuje tę zależność funkcją liniową (lub schodkową przez WoE), co jest wystarczającym przybliżeniem dla celów scoringowych, biorąc pod uwagę zysk na stabilności i interpretowalności.



Rysunek 12. Analiza zależności dla Kapitału Obrotowego Netto (Model LogReg).

6.2 Interpretacja Lokalna: Analiza Studiów Przypadku (Case Studies)


Podczas gdy interpretacja globalna pokazuje ogólne trendy, analiza lokalna pozwala zrozumieć mechanizm decyzyjny dla pojedynczego klienta. Wykorzystano metodę dekompozycji predykcji (SHAP/LIME), aby wyjaśnić, dlaczego model przyznał danej firmie określony poziom PD.

Poniżej przeanalizowano trzy reprezentatywne przypadki, ilustrujące skuteczność modelu oraz przyczyny błędnych klasyfikacji.

6.2.1 Studium Przypadku 1: Prawidłowa Detekcja Bankructwa (True Positive)

Firma: Case 9 (ID: 2515) **Rzeczywisty status:** Default (1) **Predykcja Modelu:** PD = 23.00% (Wysokie Ryzyko)

Analiza wkładu cech (Rysunek 13) jednoznacznie wskazuje na katastrofalną sytuację płynnościową.



Rysunek 13. Dekompozycja ryzyka dla firmy niewypłacalnej (Case 9). Czerwone słupki zwiększają ryzyko.

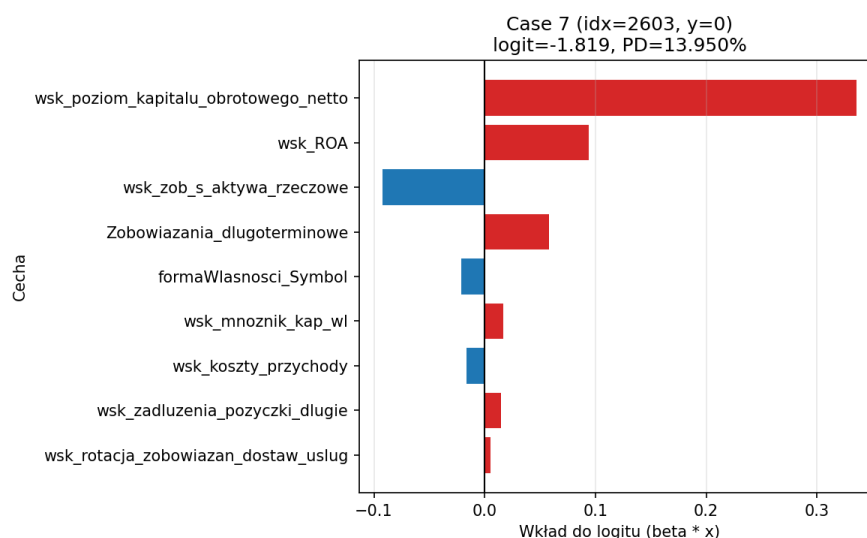
Wnioski:

- Głównym "winowajcą" jest bardzo niski poziom `wsk_poziom_kapitalu_obrotowego_netto`. Ten jeden czynnik odpowiada za największy przyrost logitu (długi czerwony słupek).
- Negatywny wpływ ma również niska rentowność aktywów (`wsk_ROA`).
- Pozytywny wpływ (niebieski słupek) wskaźnika pokrycia aktywów rzeczowych nie był w stanie zrównoważyć negatywnych sygnałów płynnościowych.
- **Ocena:** Model zadziałał poprawnie, identyfikując klasyczny syndrom utraty płynności.

6.2.2 Studium Przypadku 2: Fałszywy Alarm (False Positive)

Firma: Case 7 (ID: 2603) **Rzeczywisty status:** Zdrowa (0) **Predykcja Modelu:** PD = 13.95% (Wysokie Ryzyko)

Jest to przypadek firmy, którą model uznał za zagrożoną, mimo że w rzeczywistości przetrwała ona analizowany okres.




Rysunek 14. Analiza błędu False Positive (Case 7).

Wnioski:

- Model został "zmylony" przez niskie wskaźniki kapitału obrotowego oraz niskie ROA (czerwone słupki).
- Firma posiada jednak silne zabezpieczenie w postaci aktywów trwałych (**wsk_zob_s_aktywa_rzeczowe** - silny niebieski słupek), co sugeruje, że jest to podmiot o dużym majątku trwałym (np. produkcyjny), który naturalnie operuje na niższej płynności bieżącej.
- **Lekcja:** Model może nadmiernie penalizować firmy o specyficznej strukturze bilansu (asset-heavy), co sugeruje konieczność wdrożenia reguł eksperckich (override) dla takich podmiotów.

6.2.3 Studium Przypadku 3: Prawidłowa Ocena Dobrej Kondycji (True Negative)

Firma: Case 1 (ID: 441) **Rzeczywisty status:** Zdrowa (0) **Predykcja Modelu:** PD = 1.94% (Niskie Ryzyko)



Rysunek 15. Dekompozycja oceny dla firmy bezpiecznej (Case 1). Niebieskie słupki obniżają ryzyko.

Wnioski:

- Dominują czynniki obniżające ryzyko (niebieskie słupki).
- Wysoki poziom kapitału obrotowego (pierwsza cecha od góry) działa jako silny bufor bezpieczeństwa.
- Dodatkowo, wysoka rentowność (ROA) oraz szybka rotacja zobowiązań potwierdzają operacyjną sprawność firmy.
- Model poprawnie zidentyfikował stabilną sytuację finansową.

7 Decyzje Biznesowe: Progi i Ratingi

Ostatnim etapem wdrożenia modelu jest transformacja ciągłego prawdopodobieństwa (PD) na dyskretne decyzje (Udzielić/Odrzucić) oraz klasy ratingowe. Proces ten oparto na analizie kosztów błędów (Cost-Benefit Analysis).

7.1 Analiza Krzywej Kosztów i Wybór Punktu Odcięcia (Cutoff)

Aby określić najbardziej opłacalny próg PD, zbudowaliśmy macierz kosztów, która odzwierciedla rzeczywiste konsekwencje decyzji kredytowych. Przyjeliśmy:

- **TP – zysk na dobrze udzielonym kredycie:** +15%.
- **FP – strata na źle udzielonym kredycie:** -50%.
- **FN – koszt odrzucenia dobrego klienta:** -6%.
- **TN – korzyść z odrzucenia ryzykownego klienta:** +20%.


Uzasadnienie przyjętych wartości

Wartości w macierzy kosztów zostały dobrane tak, aby odzwierciedlały realne relacje ekonomiczne w procesie udzielania kredytu:

- **Strata na kredycie udzielonym złemu klientowi (FP) jest największa** i wynosi -50%, ponieważ w przypadku defaultu instytucja ponosi zarówno koszt utraconego kapitału, jak i dodatkowe koszty windykacji, operacyjne oraz związane z rezerwami regulacyjnymi. Strukturalnie jest to największe ryzyko biznesowe.
- **Zysk na dobrym kredycie (TP) ustalono na +15%**, co odpowiada realistycznej marży po uwzględnieniu przychodów odsetkowych oraz kosztów pozyskania kapitału. Przyjęto konserwatywną wartość, aby uniknąć przeszacowania rentowności portfela.
- **Koszt odrzucenia dobrego klienta (FN) ustawiono relatywnie nisko (-6%)**, ponieważ mimo że oznacza to utratę potencjalnego zysku, konsekwencje finansowe są niewielkie w porównaniu z ryzykiem udzielenia kredytu klientowi, który później zdefaultuje. Odrzucenie dobrego klienta kosztuje firmę jedynie utracony zysk, a nie dodatkowe straty.
- **Korzyść z odrzucenia klienta ryzykownego (TN) wyrażono jako +20%**. Wynika to z faktu, że uniknięcie potencjalnego defaultu chroni firmę przed dużą stratą (-50%). Traktujemy to jako „oszczędność” wynikającą z poprawnej decyzji odrzucającej.

Przyjęta macierz kosztów wprowadza asymetrię pomiędzy pozytywnymi i negatywnymi decyzjami kredytowymi, zgodnie z tym, że błąd typu FP jest ekonomicznie najbardziej niebezpieczny, a błąd typu FN — najmniej szkodliwy. Dzięki temu możliwe było wyznaczenie progu PD maksymalizującego oczekiwany zysk portfela.

Na Rysunku 16 przedstawiono krzywą oczekiwanego zysku w funkcji progu odcięcia dla modelu Champion (Logit).



Rysunek 16. Krzywa oczekiwanego zysku (Cost Curve) dla modelu Logit na zbiorze testowym.

Decyzja: Maksimum funkcji zysku przypada na próg **PD = 22-24%**. Oznacza to, że bank maksymalizuje wynik finansowy, akceptując klientów o prawdopodobieństwie upadłości poniżej ok. 23%. Jest to próg stosunkowo liberalny, wynikający z faktu, że w portfolio dominuje segment bezpieczny. Dla celów operacyjnych, rekomenduje się przyjęcie progu ostrożnościowego **PD = 20%**.

7.2 Mapowanie na Skalę Ratingową (Master Scale)

W oparciu o skalibrowane PD zbudowano 7-stopniową skalę ratingową, w której każda obserwacja trafia do jednej z klas:

AAA, AA, A, BBB, BB, B, CCC.

Granice klas zostały wyznaczone na podstawie kwantyli PD wykorzystywanych w modelu, odpowiadających następującym progom:

[0, 0.02987, 0.04570, 0.06662, 0.09303, 0.12797, 0.16944, 1].

Tabela 6. Skala Ratingowa oparta na przedziałach PD

Klasa	Zakres PD	Decyzja	Opis Ryzyka
AAA	0.00% – 2.987%	Akceptuj	Ryzyko minimalne
AA	2.987% – 4.569%	Akceptuj	Ryzyko bardzo niskie
A	4.569% – 6.662%	Akceptuj	Ryzyko niskie
BBB	6.662% – 9.303%	Akceptuj	Ryzyko umiarkowane
BB	9.303% – 12.797%	Akceptuj (monitoring)	Ryzyko podwyższone
B	12.797% – 16.944%	Odrzuć / decyzja warunkowa	Ryzyko wysokie
CCC	> 16.944%	Odrzuć	Ryzyko bardzo wysokie / potencjalny default

Tabela 6 pozwala na mapowanie dowolnego PD na jedną z siedmiu klas ryzyka. Skala jest monotoniczna, a granice przedziałów wynikają bezpośrednio z estymowanych rozkładów PD.

7.3 Analiza Populacji Klas Ratingowych na Zbiorze Testowym

Po zdefiniowaniu skali ratingowej przeprowadzono mapowanie obserwacji ze zbioru testowego na klasy ryzyka. Poniższe zestawienia przedstawiają strukturę portfela według modelu **Logit_WoE** oraz **XGBoost**. W każdej klasie raportowane są: liczba klientów (**n_obs**), liczba przypadków defaultu (**n_bad**), obserwowalna stopa defaultu (**bad_rate**) oraz średnie PD dla danej klasy (**avg_pd**).

Struktura Ratingowa – Logit_WoE (Test)

Tabela 7. Rating Summary – Logit_WoE – Test

Rating	n_obs	n_bad	bad_rate	avg_pd
AAA	83	2	0.024096	0.021436
AA	96	1	0.010417	0.036534
A	75	5	0.066667	0.055069
BBB	79	4	0.050633	0.080256
BB	76	9	0.118421	0.110030
B	103	15	0.145631	0.147152
CCC	88	21	0.238636	0.222038

Struktura Ratingowa – XGBoost (Test)

Tabela 8. Rating Summary – XGBoost – Test

Rating	n_obs	n_bad	bad_rate	avg_pd
AAA	130	2	0.015385	0.022251
AA	118	3	0.025424	0.037419
A	78	6	0.076923	0.055917
BBB	64	6	0.093750	0.078502
BB	81	9	0.111111	0.108765
B	54	12	0.222222	0.147944
CCC	75	19	0.253333	0.293503

Interpretacja Wyników

- Oba modele zachowują **monotoniczność ryzyka** — wraz ze wzrostem klasy ratingowej obserwowalna stopa defaultu systematycznie rośnie.
- Model **Logit_WoE** generuje bardziej „zbite” klasy w dolnej części skali (AAA–BBB), gdzie bad rate jest niższy i bardziej zgodny z PD.
- Model **XGBoost** przenosi więcej klientów do najlepszych klas (AAA, AA), co sugeruje większą „agresywność” w ocenie niskiego ryzyka, choć w klasach wysokiego ryzyka (B, CCC) obserwujemy wyższe bad rate niż w logitach.
- Dla obu modeli klasa **CCC** charakteryzuje się najwyższym ryzykiem (bad rate ok. 24–25%), co potwierdza prawidłową segmentację najbardziej ryzykownych klientów.

Ocena populacji klas potwierdza, że zaproponowana skala ratingowa skutecznie segmentuje portfel i może stanowić solidną podstawę polityki kredytowej.

8 Podsumowanie i Plany Rozwoju

Projekt zakończył się opracowaniem kompletnego, skalibrowanego i zwalidowanego narzędzia do oceny ryzyka kredytowego. Przeprowadzone analizy pozwoliły na podjęcie świadomej decyzji o wdrożeniu modelu transparentnego, przy jednoczesnym wykorzystaniu zaawansowanych technik ML do weryfikacji jego poprawności.

8.1 Wnioski Końcowe

- **Wybór Technologii:** Model Regresji Logistycznej (WoE) okazał się rozwiązaniem optymalnym. Jego minimalnie niższa siła predykcyjna (AUC 74.3%) w porównaniu do XGBoost (AUC 76.5%) jest w pełni rekompensowana przez stabilność w czasie, odporność na przeuczenie oraz łatwość interpretacji.
- **Sukces Kalibracji:** Osiągnięto strategiczny cel biznesowy, sprowadzając średnie ryzyko portfela do poziomu 4.44%. Operacja ta, choć pogorszyła statystyczne dopasowanie krzywej (ECE), zapewnia zgodność modelu z apetytem na ryzyko instytucji.
- **Zrozumienie Ryzyka:** Analiza XAI (zarówno globalna, jak i lokalna) potwierdziła, że kluczowymi determinantami upadłości są: utrata płynności (kapitał obrotowy), niska rentowność (ROA) oraz nadmierne zadłużenie. Model działa zgodnie z fundamentalną wiedzą ekonomiczną.

8.2 Rekomendacje Wdrożeniowe i Monitoring (Next Steps)

Aby zapewnić długoterminową skuteczność modelu, zaleca się wdrożenie następujących działań (zgodnie z kartą modelu - Model Card):

1. **Monitoring Stabilności (PSI):** Comiesięczna weryfikacja stabilności populacji (Population Stability Index). Jeśli PSI dla kluczowych zmiennych (np. płynności) przekroczy 0.25, konieczna będzie rekalkulacja modelu.
2. **Backtesting Kalibracji:** Kwartalna weryfikacja, czy rzeczywisty Default Rate w klasach ratingowych (A-E) pokrywa się z szacowanym PD.
3. **Reguły Eksperckie (Overrides):** Wdrożenie "sztywnej" reguły odrzucania wniosków dla firm o ujemnym kapitale własnym, niezależnie od wyniku modelu (zgodnie z wnioskami z analizy SHAP dla XGBoost).
4. **Rozwój Danych:** W przyszłych iteracjach modelu rekomenduje się włączenie zmiennych behawioralnych (historia transakcji na rachunku), co może znacząco podnieść jakość predykcji (Gini) bez utraty interpretowalności.